

# 概率论与数理统计笔记

Guotao He

2025-02-11

“All knowledge degenerates into probability.”

— David Hume

# 目录

<b>Chapter 1</b>	<b>概率论的基本概念</b>	<b>1</b>
1.1	基本概念	1
1.2	概率公式的基本计算	2
1.3	古典概率模型	3
<b>Chapter 2</b>	<b>随机变量及其分布</b>	<b>5</b>
2.1	随机变量	5
2.2	离散型随机变量及其分布律	6
2.3	常见离散型随机变量	6
2.3.1	Bernoulli 分布	6
2.3.2	二项分布	7
2.3.3	超几何分布	7
2.3.4	Poisson 分布	8
2.3.5	几何分布	8
2.3.6	Pascal 分布	8
2.3.7	多项分布	9
2.3.8	多元超几何分布	9
2.4	连续型随机变量及其分布律	10
2.5	常见连续型随机变量	10
2.5.1	均匀分布	10
2.5.2	正态分布	10
2.5.3	指数分布	11
2.5.4	Erlang 分布	11
2.5.5	$\Gamma$ 分布	12
2.5.6	$\chi^2$ 分布	12
2.5.7	多元均匀分布	12
2.5.8	多元正态分布	12
<b>Chapter 3</b>	<b>多维随机变量</b>	<b>14</b>
<b>Chapter 4</b>	<b>杂七杂八</b>	<b>15</b>
4.1	概率的连续性	15
4.2	测度论简介	15
<b>Chapter 5</b>	<b>Typst 测试章节</b>	<b>16</b>
5.1	Test Section	16
5.2	Test Test Test 02	16

DRAFT

# Chapter 1 概率论的基本概念

## 1.1 基本概念

**样本空间与样本点** 对于一个随机的试验  $E$ ，其实验的所有可能的结构构成一个集合，此集合称为随机实验  $E$  的**样本空间**，记为  $S$ ，样本空间的每一个元素被称为一个**样本点**。

**随机事件** 随机试验  $E$  的样本空间  $S$  的子集  $A$  被称为  $E$  的一个**随机事件**。特别的，由一个样本点组成的单点集，称为**基本事件**，样本空间  $S$  是自身的子集，且每次实验中必然发生，称  $S$  为  $E$  的**必然事件**，空集  $\emptyset$  不包含任何样本点，也为样本空间  $S$  的子集，其在每次实验中必然不发生， $\emptyset$  称为  $E$  的**不可能事件**。

**事件空间** 在随机试验  $E$  中的所有随机事件构成一个集合  $\mathcal{F}$ （集合的每一个元素也是集合），此集合被称为**事件空间**

事件本质上是样本空间的一个子集，因此事件之间的运算自然按集合论中集合之间的运算处理。具体而言，有：

1.  $A \subseteq B$  表示事件  $B$  包含事件  $A$ ，若  $A$  发生则  $B$  一定也发生
2.  $A = B$  表示  $A \subseteq B$  且  $B \subseteq A$
3.  $A + B = A \cup B = \{x | x \in A \text{ or } x \in B\}$
4.  $AB = A \cap B = \{x | x \in A \text{ and } x \in B\}$
5.  $A - B = \{x | x \in A \text{ and } x \notin B\}$
6.  $A \cap B = \emptyset$ ，称  $A$  与  $B$  **互斥**
7.  $A \cup B = S, A \cap B = \emptyset$ ，称  $A$  与  $B$  互为**逆事件**，互为**对立事件**
8. 记  $A$  的对立事件为  $\bar{A} = S - A$

**摩根率（对偶率）**  $\overline{A + B} = \bar{A}\bar{B}, \overline{AB} = \bar{A} + \bar{B}$

**Definition 1.1.1** (概率): 设随机试验  $E$  的样本空间为  $S$ ， $\mathcal{F}$  为  $S$  的某些子集组成的一个事件空间，如果对任一事件  $A \in \mathcal{F}$ ，定义在  $\mathcal{F}$  上的一个实值函数  $P(A)$  满足如下性质：

1. 非负性:  $\forall A \in \mathcal{F}, P(A) \geq 0$
2. 规范性（归一性）:  $P(S) = 1$
3. 可列可加性:  $\forall A_1, A_2, \dots \in \mathcal{F}$ ，且满足  $A_i A_j = \emptyset, i \neq j, i, j \in \mathbb{N}$ ，有：

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

则我们称  $P$  是  $\mathcal{F}$  上的**概率测度**，称  $P(A)$  是  $A$  的**概率**。

**Remark:** 这里的“可列可加”实际上是由测度论带来的, 这里的“可列”要求事件序列  $A_i$  是**无穷**的, 且是**可数无穷**。

当只有有限个事件序列时 (比如只有  $n$  个) 我们只需要简单地将  $A_i (i > n)$  全部定义为空集即可, 换句话说, 对于有限个互不相容的事件序列  $A_1, \dots, A_n$ , 有:

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i)$$

实际上, 上述性质被称为**“有限可加性”**, 而“可列可加性”是其到无穷情况的推广, “可列可加性”可以推出“有限可加性”, 但“有限可加性”不能推导得到“可列可加性”。因此, 我们不可用“有限可加性”去替代“可列可加性”, 即使我们大多数情况下只处理有限的情况。

换句话说, 所谓概率, 就是一个从事件空间  $\mathcal{F}$  到  $\mathbb{R}$  上的一个映射, 且满足上面三个条件。实际上, 概率的公理化条件并不直接告诉我们在实际问题中如何计算  $P(A)$ , 其只告诉了我们什么是  $P(A)$  (实际上很多数学上的公理化定义都如此),  $P(A)$  的具体计算要根据问题的条件和背景得到。

**概率空间** 所谓概率空间是一个三元组, 包含样本空间  $S$ , 事件集合  $\mathcal{F}$  和概率测度  $P$ , 记为  $(S, \mathcal{F}, P)$

**Definition 1.1.2** (条件概率): 设  $A, B$  是两个事件, 且  $P(A) > 0$ , 称:

$$P(B|A) = \frac{P(AB)}{P(A)}$$

为事件  $A$  发生的条件下事件  $B$  发生的**条件概率**。

**独立性** 对于试验  $E$  中的两个事件  $A, B$ , 若事件  $A$  发生的概率对事件  $B$  发生的概率无影响, 即  $P(AB) = P(A)P(B)$ , 则我们称事件  $A$  与  $B$  互相**独立**。更一般地, 若  $P(A_1 A_2 \dots A_n) = P(A_1)P(A_2) \dots P(A_n)$  则我们称  $A_1, A_2, \dots, A_n$  相互独立。

**Mark:** 这里需要区分  $A, B$  互相独立和  $A, B$  互相对立的区别。实际上, 事件  $A, B$  的独立性和对立性不可能同时成立, 若已知  $A, B$  对立, 且  $A$  不成立, 则我们可以马上得到  $B$  成立, 显然这不符合  $A, B$  互相独立的定义。

另外,  $A, B$  对立很容易在 Venn 图中表示, 但  $A, B$  独立不然, 究其原因是因为 Venn 图并无体现数量关系, 故无法表示  $A, B$  独立这一数量关系。

## 1.2 概率公式的基本计算

**Theorem 1.2.1** (加法公式 (Jordan 公式)): 对于概率空间  $(S, \mathcal{F}, P)$  若  $A_1, \dots, A_n \in \mathcal{F}$ , 则:

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{k=1}^n (-1)^{k-1} \sum_{1 \leq i_1 < \dots < i_k \leq n} P(A_{i_1} \dots A_{i_k})$$

**Theorem 1.2.2** (减法公式): 对于概率空间  $(S, \mathcal{F}, P)$ , 若  $A, B \in \mathcal{F}$ , 则:

$$P(A - B) = P(A) - P(AB)$$

**Theorem 1.2.3** (乘法公式): 对于概率空间  $(S, \mathcal{F}, P)$ , 若  $A_1, \dots, A_n \in \mathcal{F}$ , 则:

$$P(A_1 \dots A_n) = \prod_{i=1}^n P(A_i | A_1 \dots A_{n-1}) = \sum_{k=1}^n \sum_{1 \leq i_1 < \dots < i_k \leq n} (-1)^{k-1} P(A_{i_1} \cup \dots \cup A_{i_k})$$

**Theorem 1.2.4** (全概率公式): 对于概率空间  $(S, \mathcal{F}, P)$ , 若  $B, A_1, \dots, A_n \in \mathcal{F}$ , 其中  $A_i$  是  $S$  的分割, 则:

$$P(B) = \sum_j P(A_j)P(B|A_j)$$

**Theorem 1.2.5** (Bayes 公式): 对于概率空间  $(S, \mathcal{F}, P)$ , 若  $B, A_1, \dots, A_n \in \mathcal{F}$ , 其中  $A_i$  是  $S$  的分割, 则:

$$P(A_i | B) = \frac{P(A_i)P(B|A_i)}{\sum_j P(A_j)P(B|A_j)}$$

## 1.3 古典概率模型

**古典概型** 若试验  $E$  满足两个条件: 1. 样本空间  $S$  是有限的集合。2.  $S$  中的每个样本点发生的可能性相同。则我们称这种试验为**等可能概型**, 又称**古典概型**。

在古典概型中, 取样本空间  $S = \{e_1, \dots, e_n\}$ , 其中  $e_1, \dots, e_n$  代表该随机试验的  $N$  个结果, 事件域  $\mathcal{F}$  取为  $2^S$  (即  $S$  的所有子集都是事件), 且每个基本事件发生的可能性相同, 即

$$P(\{e_1\}) = P(\{e_2\}) = \dots = P(\{e_n\})$$

若事件  $A$  包含  $K$  个基本事件, 即  $A = \{e_{i_1}\} \cup \dots \cup \{e_{i_n}\}$ , 则给出概率测度  $P$  如下:

$$P(A) = \frac{K}{N} = \sum_{e \in A} \frac{1}{N}$$

由于古典概型的概率与计数直接相关, 因此下文中简要介绍一些基本的组合计数方法:

**乘法原理** 设某个试验共包含  $r$  个依次执行的阶段, 其中: 1. 第一个阶段总共有  $n_1$  个可能的结果。2. 在完全前面的  $i-1$  个阶段并得到一个相应的结果后, 第  $i$  个阶段将总共有  $n_i$  个可能的结果。则该试验一共有  $n_1 \cdot n_2 \cdot \dots \cdot n_r$  个可能的结果。

**加法原理** 设完成某个试验有  $r$  种不同的途径, 且只能在这  $r$  种途径中选一种来完成该试验。若采取第  $i$  种途径时总共有  $n_i$  种可能的结果, 则该试验一共有  $n_1 + n_2 + \dots + n_r$  种可能的结果。

**排列** 假设有  $n$  个不同的个体, 从中选出  $n$  个并将其排成一个序列, 则总共有:

$$n(n-1)(n-2)\dots(n-m+1) = \frac{n!}{(n-m)!}$$

个可能的组合方式。

**组合** 假设一个集合包含  $n$  个不同的元素, 我们需要从中选出  $m$  个元素构成一个子集, 则可能得到的子集总共有:

$$\frac{n(n-1)\dots(n-m+1)}{m!} = \frac{n!}{m!(n-m)!}$$

个, 上式给出的整数常常又被称为**二项式系数**, 记作  $\binom{n}{m}$

**多项式系数** 给定一组自然数  $n_1, n_2, \dots, n_r$ , 以及  $n = n_1 + \dots + n_r$ , 定义多项式系数为:

$$\binom{n}{n_1, n_2, \dots, n_r} = \frac{n!}{n_1! n_2! \dots n_r!}$$



## Chapter 2 随机变量及其分布

### 2.1 随机变量

“随机变量”可以看成是将“底层”的概率空间  $(S, \mathcal{F}, P)$  “包装”成分布函数，分布列，概率密度等方便使用微积分等分析工具的“接口”，从而为我们对概率进行建模提供了莫大的便利。

**Definition 2.1.1** (随机变量): 设  $(S, \mathcal{F}, P)$  为一概率空间，我们将定义在  $S$  上的实值函数  $X: S \rightarrow \mathbb{R}$  称作一个**随机变量**，若对于任意  $\mathbb{R}$  中的区间  $I$ ，均有：

$$\{e \in S | X(e) \in I\} \in \mathcal{F}$$

上述定义中，要求  $\{e \in S | X(e) \in I\} \in \mathcal{F}$ ，其保证了  $\{e \in S | X(e) \in I\}$  的概率都是有定义的，也就是对任意区间  $I$ ，我们都可以谈论“随机变量的取值落在  $I$  中”这一事件的概率。

*Remark:* 上述条件实际上是从**可测性**而来，即对于实数轴上的任意的“合理”的子集（Borel 集），其原像都必须是一个可测事件（即属于事件域）同时，上述要求的一个常见的等价描述如下：“对于任意实数  $x$ ，集合  $\{e | X(e) \leq x\}$  有确定的概率”。

另外，不满足上述条件的情况实际应用中极少出现，相关例子基本属于高等概率论的内容，其基本都是数学上卡 BUG 而来，一般可忽略不理。

对于给定的随机变量  $X$  以及关于实数  $x$  的命题  $\varphi(x)$ ，我们常用记号  $\{\varphi(X)\}$  表示集合  $\{e \in S | \varphi(X(e)) \text{ 成立}\}$ ，例如：

$$\{X > 2\} = \{e \in S | X(e) > 2\}$$

同时，上述集合显然构成一个事件，此事件发生的概率可简记为： $P\{\varphi(X)\}$ 。

随机变量之间可以进行运算，具体而言，给定  $n$  个随机变量  $X_1, X_2, \dots, X_n$  以及函数  $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ，我们用  $f(X_1, \dots, X_n)$  表示将  $e \in S$  映射为  $f(X_1(e), X_2(e), \dots, X_n(e))$  的函数。

许多情况下，我们关系不止一个随机变量，而是多个随机变量  $X_1, \dots, X_n$  的相互关系，此时我们可以将这些随机变量作为整体进行研究，故有随机向量定义如下：

**Definition 2.1.2** (随机向量): 给定  $n$  个随机变量  $X_1, \dots, X_n$ ，我们将它们构成的有序组  $(X_1, \dots, X_n)$  称为  $n$  维随机向量。

**Note:** 我们默认将形如  $(a_1, \dots, a_n)$  的有序组（包括数组和随机向量）均看成列向量.

## 2.2 离散型随机变量及其分布律

**Definition 2.2.1** (离散型随机变量、分布列): 设  $X$  为一随机变量, 若  $X$  只有可数多个可能的取值, 则称  $X$  为离散型随机变量.

同时, 我们定义分布列  $p_X: \mathbb{R} \rightarrow [0, 1]$  为:

$$p_X(x) = P\{X = x\}, \quad x \in \mathbb{R}$$

显然, 分布列满足如下性质:

**Theorem 2.2.1:** 设  $X$  为一离散型随机变量,  $p_X$  为其分布列, 则:

1. 对任意  $x \in \mathbb{R}$ , 均有  $p_X(x) \geq 0$
2.  $\{x \in \mathbb{R} | p_X(x) > 0\}$  为可数集
3.  $\sum_x p_X(x) = 1$

此定理的逆定理同样成立.

对于随机向量, 上述定义可进行推广如下:

**Definition 2.2.2** (离散型随机向量、联合分布列): 若  $X_1, \dots, X_n$  均为离散型随机变量, 则称  $\mathbf{X} = (X_1, \dots, X_n)$  为离散型随机向量, 其联合分布列被定义为函数:

$$p_{X_1, \dots, X_n}(x_1, \dots, x_n) = P\{X_1 = x_1, \dots, X_n = x_n\}$$

## 2.3 常见离散型随机变量

### 2.3.1 Bernoulli 分布

**Bernoulli 试验** 我们称事件  $E$  为 Bernoulli 试验, 当试验  $E$  中有且只有两种可能的结果:  $A$  以及  $\bar{A}$ .

**Definition 2.3.1** (Bernoulli 分布): 若事件  $E$  为 Bernoulli 试验, 记随机变量  $X$  为事件  $A$  出现的次数, 且只可能取 0 或 1, 则称随机变量  $X$  服从 Bernoulli 分布, 记为  $X \sim B(1, p)$ , 其分布列为:

$$P\{X = k\} = p^k(1 - p)^{1-k}, k \in \{0, 1\}$$

其中  $p$  为事件  $A$  发生的概率.

其特征如下:

- 数学期望:  $E(X) = P(A)$
- 方差:  $D(X) = p(1 - p)$

Bernoulli 分布又被称为两点分布或(0-1)分布.

### 2.3.2 二项分布

**$n$  重 Bernoulli 试验** 若事件  $E$  为 Bernoulli 试验, 且独立重复  $n$  次, 则称这一串重复的试验为  $n$  重 Bernoulli 试验.

**Definition 2.3.2** (二项分布): 若事件  $E$  为  $n$  重 Bernoulli 试验, 记  $X$  为事件  $A$  出现的次数, 取值为  $0, 1, \dots, n$ , 则称随机变量  $X$  服从二项分布, 记为  $X \sim B(n, p)$ , 其分布列为:

$$P\{X = k\} = b(k; n, p) = \binom{n}{k} p^k (1 - p)^{n-k}$$

其中,  $p$  为每一此试验中  $A$  出现的概率.

其具有如下性质:

- 对称性:  $b(k; n, p) = b(n - k; n, 1 - p)$
- 单调性: 当  $k \leq (n + 1)p$  时单调增, 当  $k > (n + 1)p$  时单调减
- 当  $p$  相当小时, 可以使用 Poisson 逼近, 有:

$$b(k; n, p) \approx \frac{(np)^k}{k!} e^{-np}$$

其特征如下:

- 数学期望:  $E(X) = np$
- 方差:  $D(X) = np(1 - p)$
- 特征函数:  $f(t) = (pe^{it} + q)^n$

### 2.3.3 超几何分布

**Definition 2.3.3** (超几何分布): 某批  $N$  件产品有  $M$  件次品, 随机抽出  $n$  件, 令随机变量  $X$  为抽出次品数量, 称其满足超几何分布, 记为  $X \sim H(n, M, N)$ , 其分布列为:

$$P\{X = k\} = f(k; n, M, N) = \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}}, 0 \leq k \leq n \leq N, k \leq M$$

当  $N \gg n$  时, 可以使用二项分布近似.

### 2.3.4 Poisson 分布

**Definition 2.3.4** (Poisson 分布): 设  $\lambda > 0$  且随机变量  $X$  可以取一切非负整数, 则称随机变量  $X$  服从 Poisson 分布, 若:

$$P\{X = k\} = \frac{\lambda^k}{k!} e^{-\lambda}, k \in \mathbb{N}$$

其特征如下:

- 数学期望:  $E(X) = \lambda$
- 方差:  $D(X) = \lambda$
- 特征函数:  $f(t) = e^{\lambda(e^{it}-1)}$

### 2.3.5 几何分布

**Definition 2.3.5** (几何分布): 在成功概率为  $p$  的 Bernoulli 试验中, 记随机变量  $X$  为首次试验时试验的次数, 其可能的取值为  $1, 2, \dots$ , 则称随机变量  $X$  服从几何分布, 记为  $X \sim G(p)$ , 其分布列为:

$$P\{X = k\} = g(k; p) = p(1-p)^{k-1}, k \in \mathbb{N}^+$$

其特征如下:

- 数学期望:  $E = \frac{1}{p}$

同时, 几何分布还具有**无记忆性**, 即若已知前  $m$  次都没有成功, 设达到首次成功的等待时间为  $T$ , 则  $P(T = k) = p(1-p)^{k-1}, k \in \mathbb{N}^+$  同  $m$  无关, 离散分布中只有几何分布有此性质.

### 2.3.6 Pascal 分布

**Definition 2.3.6** (Pascal 分布): 在成功概率为  $p$  的 Bernoulli 试验中, 记随机变量  $X$  为成功第  $r$  次出现时的试验次数, 取值为  $r, r+1, \dots$ , 称随机变量  $X$  服从 Pascal 分布, 其分布列为:

$$P\{X = k\} = \binom{k-1}{r-1} p^r (1-p)^{k-r}, k = r, r+1, \dots$$

上述可推广成负二项分布:

**Definition 2.3.7** (负二项分布): 对任意实数  $r > 0$ , 称

$$Nb(k; r, p) = \binom{-r}{k} p^r (p-1)^k, k \in \mathbb{N}$$

为负二项分布.

### 2.3.7 多项分布

**Definition 2.3.8** (多项分布): 设试验可能的结果为  $A_1, \dots, A_r$ ,  $P(A_i) = p_i$ , 且  $p_1 + \dots + p_r = 1$ , 重复  $n$  次试验, 每次试验独立, 记随机变量  $X_i$  为  $A_i$  出现次数, 则称随机向量  $(X_1, \dots, X_r)$  服从多项分布, 分布列为:

$$P\{X_1 = k_1, \dots, X_r = k_r\} = \frac{n!}{k_1! \dots k_r!} p_1^{k_1} \dots p_r^{k_r}$$

其具有如下性质:

- 协方差:  $\text{con}(X_i, X_j) = -np_i p_j$
- 相关系数:  $\rho = -\sqrt{\frac{p_i p_j}{(1-p_i)(1-p_j)}}$

### 2.3.8 多元超几何分布

**Definition 2.3.9** (多元超几何分布): 设袋子中有  $N_i$  个  $i$  号球,  $i = 1, 2, \dots, r$ , 且  $N_1 + \dots + N_r = N$ , 从中摸出  $n$  只, 记随机变量  $X_i$  为  $i$  号球出现的次数, 则称随机向量  $(X_1, \dots, X_r)$  服从多元超几何分布, 分布列为:

$$P(X_1 = n_1, \dots, X_r = n_r) = \frac{\binom{N_1}{n_1} \dots \binom{N_r}{n_r}}{\binom{N}{n}}$$

## 2.4 连续型随机变量及其分布律

## 2.5 常见连续型随机变量

### 2.5.1 均匀分布

**Definition 2.5.1** (均匀分布): 设  $a, b$  为有限数, 则密度函数为:

$$p(x) = \begin{cases} \frac{1}{b-a} & \text{if } a \leq x \leq b \\ 0 & \text{Others} \end{cases}$$

此被称为  $[a, b]$  上的均匀分布.

- 其分布函数如下:

$$F(x) = \begin{cases} 0 & \text{if } x \leq a \\ \frac{x-a}{b-a} & \text{if } a < x \leq b \\ 1 & \text{if } x > b \end{cases}$$

- 若  $\theta$  服从  $[0, 1]$  均匀分布, 那么对任意分布函数  $F(x)$ , 令  $\xi = F^{-1}(\theta)$ , 则不难看出  $\xi$  是服从分布函数  $F$  的随机变量.

其特征如下:

- 数学期望:  $E(X) = \frac{b+a}{2}$
- 方差:  $D(X) = \frac{(b-a)^2}{12}$

### 2.5.2 正态分布

**Definition 2.5.2** (正态分布): 密度函数为

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, x \in \mathbb{R}$$

其中  $\sigma > 0, \mu, \sigma$  为常数, 上述分布记为  $N(\mu, \sigma^2)$ .

- 其分布函数如下:

$$F(x) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^x \frac{e^{-(y-\mu)^2}}{2\sigma^2} dy, x \in \mathbb{R}$$

- 当  $\mu = 0, \sigma = 1$  时称其为标准正态分布，其密度函数和分布函数分别记为  $\phi$  和  $\Phi$

其具有如下性质：

- 若  $\xi \sim N(\mu, \sigma^2)$ ，则  $\eta = \frac{\xi - \mu}{\sigma} \sim N(0, 1)$
- 若  $\xi \sim N(\mu, \sigma^2)$ ，则  $F(x) = P\left(\frac{\xi - \mu}{\sigma} < \frac{x - \mu}{\sigma}\right) = \Phi\left(\frac{x - \mu}{\sigma}\right)$ ，且  $P(|\xi - \mu| < k\sigma) = 2\Phi(k) - 1$ ，且  $P(a \leq \xi \leq b) = \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right)$
- 相互独立分布相同的两个随机变量  $\xi, \eta$  如果满足密度函数不等于 0 且二阶可导，且  $\xi + \eta, \xi - \eta$  相互独立，那么  $\xi, \eta, \xi + \eta, \xi - \eta$  都服从正态分布.

其特征如下：

- 数学期望： $E(X) = \mu$
- 方差： $D(X) = \sigma^2$ ， $\sigma$  被称为标准差
- 特征函数： $f(t) = \exp(i\mu t - \frac{1}{2}\sigma^2 t^2)$

### 2.5.3 指数分布

**Definition 2.5.3** (指数分布)：密度函数为

$$p(x) = \begin{cases} \lambda e^{-\lambda x} & \text{if } x \geq 0 \\ 0 & \text{if } x < 0 \end{cases}$$

这里  $\lambda > 0$  为参数，称为指数分布，记为  $\text{Exp}(\lambda)$ .

其具有如下性质：

- 无记忆性：对于任意的  $s, t > 0$ ，有  $P(\xi \geq s + t | \xi \geq s) = P(\xi \geq t)$  (连续分布里只有指数分布有此性质)

其特征如下：

- 数学期望： $E = \frac{1}{\lambda}$

### 2.5.4 Erlang 分布

**Definition 2.5.4** (Erlang 分布)：对于任意的  $r \in \mathbb{N}^+, \lambda > 0$ ，密度函数：

$$p(x) = \frac{\lambda^r}{(r-1)!} x^{r-1} e^{-\lambda x}, x > 0$$

称为 Erlang 分布.

2.5.5  $\Gamma$  分布

**Definition 2.5.5** ( $\Gamma$  分布): 对任意的  $r, \lambda > 0$ , 密度函数:

$$f(x) = \begin{cases} \frac{\lambda^r}{\Gamma(r)} x^{r-1} e^{-\lambda x} & \text{if } x > 0 \\ 0 & \text{if } x \leq 0 \end{cases}$$

称为  $\Gamma$  分布.

2.5.6  $\chi^2$  分布

**Definition 2.5.6** ( $\chi^2$  分布): 密度函数为:

$$p(x) = \frac{1}{2^{n/2} \Gamma(n/2)} x^{n/2-1} e^{-(x/2)}, x > 0$$

的分布称为具有自由度  $n$  的  $\chi^2$  分布, 记作  $\chi_n^2$ .

- 不难得知  $\chi^2$  分布是  $\Gamma$  分布的特例.
- 若相对独立的  $\chi^2$  分布  $\xi, \eta$  自由度分别为  $m, n$ , 则  $\xi + \eta$  服从  $m + n$  的  $\chi^2$  分布.
- 对相对独立且服从  $N(0, 1)$  的随机变量  $\xi_1, \dots, \xi_n$ , 则  $\eta = \xi_1^2 + \dots + \xi_n^2$  服从  $\chi^2$  分布.

## 2.5.7 多元均匀分布

**Definition 2.5.7** (多元均匀分布): 若  $G \subset \mathbb{R}^n$  的正测有限区域, 则密度函数:

$$p(x_1, \dots, x_n) = \begin{cases} \frac{1}{m(G)} & \text{if } (x_1, \dots, x_n) \in G \\ 0 & \text{if } (x_1, \dots, x_n) \notin G \end{cases}$$

称为多元均匀分布.

## 2.5.8 多元正态分布



**Definition 2.5.8** (多元正态分布): 若  $\Sigma = (\sigma_{ij})$  是  $n$  阶正定矩阵, 设逆矩阵  $\Sigma^{-1} = (\gamma_{ij})$ , 设  $\mu = (\mu_1, \dots, \mu_n)^\top$  为任意实值列向量, 则有密度函数:

$$\begin{aligned} p(x_1, \dots, x_n) &= \frac{1}{(2\pi)^{n/2}(\det \Sigma)^{1/2}} \exp\left(-\frac{1}{2} \sum_{j,k=1}^n r_{jk}(x_j - \mu_j)(x_k - \mu_k)\right) \\ &= \frac{1}{(2\pi)^{n/2}(\det \Sigma)^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^\top \Sigma^{-1}(\mathbf{x} - \mu)\right) \end{aligned}$$

定义的分佈为  $n$  元正态分佈, 记为  $N(\mu, \Sigma)$ .

## Chapter 3 多维随机变量

DRAFT

## Chapter 4 杂七杂八

### 4.1 概率的连续性

### 4.2 测度论简介

DRAFT

## Chapter 5 Typst 测试章节

### 5.1 Test Section

§5.1

### 5.2 Test Test Test 02