

概率论与数理统计笔记

Guotao He

Build: 2025-03-06

Typst Version: 0.13.0

“All knowledge degenerates into probability.”

— David Hume

目录

1	概率论的基本概念	1
1.1	基本概念	1
1.2	概率公式的基本计算	2
1.3	条件概率和独立性	3
1.4	古典概率模型	4
2	随机变量及其分布	6
2.1	随机变量	6
2.2	离散型随机变量及其分布律	6
2.3	常见离散型随机变量	7
2.3.1	Bernoulli 分布	7
2.3.2	二项分布	7
2.3.3	超几何分布	8
2.3.4	Poisson 分布	8
2.3.5	几何分布	9
2.3.6	Pascal 分布	9
2.4	连续型随机变量及其分布律	9
2.5	常见连续型随机变量	10
2.5.1	均匀分布	10
2.5.2	正态分布	11
2.5.3	指数分布	11
2.5.4	Erlang 分布	12
2.5.5	Γ 分布	12
2.5.6	χ^2 分布	12
3	多维随机变量	13
3.1	随机向量及其联合分布	13
3.2	离散型随机向量及其分布律	13
3.3	常见离散型随机向量	13
3.3.1	多项分布	13
3.3.2	多元超几何分布	14
3.4	连续型随机向量及其分布律	14
3.5	常见连续型随机向量	14
3.5.1	多元均匀分布	14
3.5.2	多元正态分布	14
4	杂七杂八	16
4.1	概率的连续性	16
4.2	测度论简介	16

5	Typst 测试章节	17
5.1	Test Section	17
5.2	Test Test Test 02	17

DRAFT

Chapter 1 概率论的基本概念

1.1 基本概念

样本空间与样本点 对于一个随机的试验 E , 其实验的所有可能的结构构成一个集合, 此集合称为随机实验 E 的**样本空间**, 记为 S , 样本空间的每一个元素被称为一个**样本点**。

随机事件 随机试验 E 的样本空间 S 的子集 A 被称为 E 的一个**随机事件**。特别的, 由一个样本点组成的单点集, 称为**基本事件**, 样本空间 S 是自身的子集, 且每次实验中必然发生, 称 S 为 E 的**必然事件**, 空集 \emptyset 不包含任何样本点, 也为样本空间 S 的子集, 其在每次实验中必然不发生, \emptyset 称为 E 的**不可能事件**。

事件空间 在随机试验 E 中的所有随机事件构成一个集合 \mathcal{F} (集合的每一个元素也是集合), 此集合被称为**事件空间**

事件本质上是样本空间的一个子集, 因此事件之间的运算自然按集合论中集合之间的运算处理。具体而言, 有:

1. $A \subseteq B$ 表示事件 B 包含事件 A , 若 A 发生则 B 一定也发生
2. $A = B$ 表示 $A \subseteq B$ 且 $B \subseteq A$
3. $A + B = A \cup B = \{x | x \in A \text{ or } x \in B\}$
4. $AB = A \cap B = \{x | x \in A \text{ and } x \in B\}$
5. $A - B = \{x | x \in A \text{ and } x \notin B\}$
6. $A \cap B = \emptyset$, 称 A 与 B **互斥**
7. $A \cup B = S, A \cap B = \emptyset$, 称 A 与 B 互为**逆事件**, 互为**对立事件**
8. 记 A 的对立事件为 $\bar{A} = S - A$

De Morgan 律 (对偶率) $\overline{A + B} = \bar{A}\bar{B}, \overline{AB} = \bar{A} + \bar{B}$

上述定律可推广到 n 个事件:

$$\overline{\bigcup_{i=1}^n A_i} = \bigcap_{i=1}^n \bar{A}_i, \quad \overline{\bigcap_{i=1}^n A_i} = \bigcup_{i=1}^n \bar{A}_i$$

Definition 1.1.1 (概率): 设随机试验 E 的样本空间为 S , \mathcal{F} 为 S 的某些子集组成的一个事件空间, 如果对任一事件 $A \in \mathcal{F}$, 定义在 F 上的一个实值函数 $P(A)$ 满足如下性质:

1. **非负性:** $\forall A \in \mathcal{F}, P(A) \geq 0$
2. **规范性 (归一性):** $P(S) = 1$
3. **可列可加性:** $\forall A_1, A_2, \dots \in \mathcal{F}$, 且满足 $A_i A_j = \emptyset, i \neq j, i, j \in \mathbb{R}$, 有:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

则我们称 P 是 \mathcal{F} 上的概率测度, 称 $P(A)$ 是 A 的概率。

Remark: 这里的“可列可加”实际上是由测度论带来的, 这里的“可列”要求事件序列 A_i 是**无穷**的, 且是**可数无穷**。

当只有有限个事件序列时 (比如只有 n 个) 我们只需要简单地将 $A_i (i > n)$ 全部定义为空集即可, 换句话说, 对于有限个互不相容的事件序列 A_1, \dots, A_n , 有:

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i)$$

实际上, 上述性质被称为**“有限可加性”**, 而“可列可加性”是其到无穷情况的推广, “可列可加性”可以推出“有限可加性”, 但“有限可加性”不能推导得到“可列可加性”。因此, 我们不可用“有限可加性”去替代“可列可加性”, 即使我们大多数情况下只处理有限的情况。

换句话说, 所谓概率, 就是一个从事件空间 \mathcal{F} 到 \mathbb{R} 上的一个映射, 且满足上面三个条件。实际上, 概率的公理化条件并不直接告诉我们在实际问题中如何计算 $P(A)$, 其只告诉了我们什么是 $P(A)$ (实际上很多数学上的公理化定义都如此), $P(A)$ 的具体计算要根据问题的条件和背景得到。

Mark: 对于**不可列**的样本空间, 需要注意其中的**可列个点集的概率可以¹为0**。

概率空间 所谓概率空间是一个三元组, 包含样本空间 S , 事件集合 \mathcal{F} 和概率测度 P , 记为 (S, \mathcal{F}, P)

1.2 概率公式的基本计算

Theorem 1.2.1 (加法公式 (Jordan 公式)): 对于概率空间 (S, \mathcal{F}, P) 若 $A_1, \dots, A_n \in \mathcal{F}$, 则:

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{k=1}^n (-1)^{k-1} \sum_{1 \leq i_1 < \dots < i_k \leq n} P(A_{i_1} \dots A_{i_k})$$

¹一般而言不可列样本空间中可列点集的概率测度一般都为 0, 但测度论中确实有其他情况使得可列点集的概率测度不为 0。

Theorem 1.2.2 (减法公式): 对于概率空间 (S, \mathcal{F}, P) , 若 $A, B \in \mathcal{F}$, 则:

$$P(A - B) = P(A) - P(AB)$$

Theorem 1.2.3 (乘法公式): 对于概率空间 (S, \mathcal{F}, P) , 若 $A_1, \dots, A_n \in \mathcal{F}$, 则:

$$P(A_1 \dots A_n) = \prod_{i=1}^n P(A_i | A_1 \dots A_{i-1}) = \sum_{k=1}^n \sum_{i_1 < \dots < i_k} (-1)^{k-1} P(A_{i_1} \cup \dots \cup A_{i_k})$$

Theorem 1.2.4 (全概率公式): 对于概率空间 (S, \mathcal{F}, P) , 若 $B, A_1, \dots, A_n \in \mathcal{F}$, 其中 A_i 是 S 的分割 (又称完备事件群, 英文为 Partition), 则:

$$P(B) = \sum_j P(A_j)P(B|A_j)$$

Theorem 1.2.5 (Bayes 公式): 对于概率空间 (S, \mathcal{F}, P) , 若 $B, A_1, \dots, A_n \in \mathcal{F}$, 其中 A_i 是 S 的分割, 则:

$$P(A_i|B) = \frac{P(A_i)P(B|A_i)}{\sum_j P(A_j)P(B|A_j)}$$

1.3 条件概率和独立性

Definition 1.3.1 (条件概率): 设 A, B 是两个事件, 且 $P(A) > 0$, 称:

$$P(B|A) = \frac{P(AB)}{P(A)}$$

为事件 A 发生的条件下事件 B 发生的条件概率。

条件概率具有如下性质: 给定事件 A 发生, $P(A) > 0$:

- $0 \leq P(B|A) \leq 1$
- $0 \leq P(S|A) = 1$
- 若 $B_1 B_2 = \emptyset$, 则 $P(B_1 + B_2|A) = P(B_1|A) + P(B_2|A)$

独立性 对于试验 E 中的两个事件 A, B , 若事件 A 发生的概率对事件 B 发生的概率无影响, 即 $P(AB) = P(A)P(B)$, 则我们称事件 A 与 B 互相独立。更一般地, 若 $P(A_1 A_2 \dots A_n) = P(A_1)P(A_2) \dots P(A_n)$ 则我们称 A_1, A_2, \dots, A_n 相互独立。

Mark: 注意一般而言 A_1, \dots, A_n 两两独立和相互独立并不相同。具体而言, 两两独立指的是从 A_1, \dots, A_n 中任取两个, 均有 $P(A_i A_j) = P(A_i)P(A_j)$ 。而相互独立指的是 $P(A_1 \dots A_n) = P(A_1) \dots P(A_n)$ 。相互独立一定两两独立, 但两两独立不一定相互独立。




图 1.3-1 Borromean Ring,
任意两个环两两不相交, 但整体无法解开

Mark: 这里需要区分 A, B 独立和 A, B 对立的区别。实际上, 事件 A, B 的独立性和对立性不可能同时成立, 若已知 A, B 对立, 且 A 不成立, 则我们可以马上得到 B 成立, 显然这不符合 A, B 互相独立的定义。

另外, A, B 对立很容易在 Venn 图中表示, 但 A, B 独立不然, 究其原因是因为 Venn 图并无体现数量关系, 故无法表示 A, B 独立这一数量关系。

1.4 古典概率模型

古典概型 若试验 E 满足两个条件: 1. 样本空间 S 是有限的集合。2. S 中的每个样本点发生的可能性相同。则我们称这种试验为等可能概型, 又称古典概型。

在古典概型中, 取样本空间 $S = \{e_1, \dots, e_n\}$, 其中 e_1, \dots, e_n 代表该随机试验的 N 个结果, 事件域 \mathcal{F} 取为 2^S (即 S 的所有子集都是事件), 且每个基本事件发生的可能性相同, 即

$$P(\{e_1\}) = P(\{e_2\}) = \dots = P(\{e_n\})$$

若事件 A 包含 K 个基本事件, 即 $A = \{e_{i_1}\} \cup \dots \cup \{e_{i_n}\}$, 则给出概率测度 P 如下:

$$P(A) = \frac{K}{N} = \sum_{e \in A} \frac{1}{N}$$

由于古典概型的概率与计数直接相关, 因此下文中简要介绍一些基本的组合计数方法:

乘法原理 设某个试验共包含 r 个依次执行的阶段，其中：1. 第一个阶段总共有 n_1 个可能的结果。2. 在完全前面的 $i-1$ 个阶段并得到一个相应的结果后，第 i 个阶段将总共有 n_i 个可能的结果。则该试验一共有 $n_1 \cdot n_2 \cdot \dots \cdot n_r$ 个可能的结果。

加法原理 设完成某个试验有 r 种不同的途径，且只能在这 r 种途径中选一种来完成该试验。若采取第 i 种途径时总共有 n_i 种可能的结果，则该试验一共有 $n_1 + n_2 + \dots + n_r$ 种可能的结果。

排列 假设有 n 个不同的个体，从中选出 m 个并将其排成一个序列，则总共有：

$$n(n-1)(n-2)\dots(n-m+1) = \frac{n!}{(n-m)!}$$

个可能的组合方式。

组合 假设一个集合包含 n 个不同的元素，我们需要从中选出 m 个元素构成一个子集，则可能得到的子集总共有：

$$\frac{n(n-1)\dots(n-m+1)}{m!} = \frac{n!}{m!(n-m)!}$$

个，上式给出的整数常常又被称为**二项式系数**，记作 $\binom{n}{m}$

多项式系数 给定一组自然数 n_1, n_2, \dots, n_r ，以及 $n = n_1 + \dots + n_r$ ，定义多项式系数为：

$$\binom{n}{n_1, n_2, \dots, n_r} = \frac{n!}{n_1! n_2! \dots n_r!}$$

Chapter 2 随机变量及其分布

2.1 随机变量

“随机变量”可以看成是将“底层”的概率空间 (S, \mathcal{F}, P) “包装”成分布函数，分布列，概率密度等方便使用微积分等分析工具的“接口”，从而为我们对概率进行建模提供了莫大的便利。

Definition 2.1.1 (随机变量): 设 (S, \mathcal{F}, P) 为一概率空间，我们将定义在 S 上的实值函数 $X: S \rightarrow \mathbb{R}$ 称作一个**随机变量**，若对于任意 \mathbb{R} 中的区间 I ，均有：

$$\{e \in S | X(e) \in I\} \in \mathcal{F}$$

上述定义中，要求 $\{e \in S | X(e) \in I\} \in \mathcal{F}$ ，其保证了 $\{e \in S | X(e) \in I\}$ 的概率都是有定义的，也就是对任意区间 I ，我们都可以谈论“随机变量的取值落在 I 中”这一事件的概率。

Remark: 上述条件实际上是从**可测性**而来，即对于实数轴上的任意的“合理”的子集（Borel 集），其原像都必须是一个可测事件（即属于事件域）同时，上述要求的一个常见的等价描述如下：“对于任意实数 x ，集合 $\{e | X(e) \leq x\}$ 有确定的概率”。

另外，不满足上述条件的情况实际应用中极少出现，相关例子基本属于高等概率论的内容，其基本都是数学上卡 BUG 而来，一般可忽略不理。

对于给定的随机变量 X 以及关于实数 x 的命题 $\varphi(x)$ ，我们常用记号 $\{\varphi(X)\}$ 表示集合 $\{e \in S | \varphi(X(e)) \text{ 成立}\}$ ，例如：

$$\{X > 2\} = \{e \in S | X(e) > 2\}$$

同时，上述集合显然构成一个事件，此事件发生的概率可简记为： $P\{\varphi(X)\}$ 。

随机变量之间可以进行运算，具体而言，给定 n 个随机变量 X_1, X_2, \dots, X_n 以及函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ，我们用 $f(X_1, \dots, X_n)$ 表示将 $e \in S$ 映射为 $f(X_1(e), X_2(e), \dots, X_n(e))$ 的函数。

2.2 离散型随机变量及其分布律

Definition 2.2.1 (离散型随机变量、分布列): 设 X 为一随机变量，若 X 只有可数多个可能的取值，则称 X 为**离散型随机变量**。

同时，我们定义分布列 $p_X: \mathbb{R} \rightarrow [0, 1]$ 为：

$$p_X(x) = P\{X = x\}, \quad x \in \mathbb{R}$$

显然，分布列满足如下性质：

Theorem 2.2.1: 设 X 为一离散型随机变量， p_X 为其分布列，则：

1. 对任意 $x \in \mathbb{R}$ ，均有 $p_X(x) \geq 0$
2. $\{x \in \mathbb{R} | p_X(x) > 0\}$ 为可数集
3. $\sum_x p_X(x) = 1$

此定理的逆定理同样成立.

2.3 常见离散型随机变量

2.3.1 Bernoulli 分布

Bernoulli 试验 我们称事件 E 为 Bernoulli 试验，当试验 E 中有且只有两种可能的结果： A 以及 \bar{A} .

Definition 2.3.1 (Bernoulli 分布): 若事件 E 为 Bernoulli 试验，记随机变量 X 为事件 A 出现的次数，且只可能取 0 或 1，则称随机变量 X 服从 Bernoulli 分布，记为 $X \sim B(1, p)$ ，其分布列为：

$$P\{X = k\} = p^k(1-p)^{1-k}, k \in \{0, 1\}$$

其中 p 为事件 A 发生的概率.

其特征如下：

- 数学期望： $E(X) = P(A)$
- 方差： $D(X) = p(1-p)$

Bernoulli 分布又被称为**两点分布**或**(0-1) 分布**.

2.3.2 二项分布

n 重 Bernoulli 试验 若事件 E 为 Bernoulli 试验，且**独立**重复 n 次，则称这一串重复的试验为 n 重 Bernoulli 试验.

Definition 2.3.2 (二项分布): 若事件 E 为 n 重 Bernoulli 试验, 记 X 为事件 A 出现的次数, 取值为 $0, 1, \dots, n$, 则称随机变量 X 服从二项分布, 记为 $X \sim B(n, p)$, 其分布列为:

$$P\{X = k\} = b(k; n, p) = \binom{n}{k} p^k (1-p)^{n-k}$$

其中, p 为每一此试验中 A 出现的概率.

其具有如下性质:

- 对称性: $b(k; n, p) = b(n-k; n, 1-p)$
- 单调性: 当 $k \leq (n+1)p$ 时单调增, 当 $k > (n+1)p$ 时单调减
- 当 p 相当小时, 可以使用 Poisson 逼近, 有:

$$b(k; n, p) \approx \frac{(np)^k}{k!} e^{-np}$$

其特征如下:

- 数学期望: $E(X) = np$
- 方差: $D(X) = np(1-p)$
- 特征函数: $f(t) = (pe^{it} + q)^n$

2.3.3 超几何分布

Definition 2.3.3 (超几何分布): 某批 N 件产品有 M 件次品, 随机抽出 n 件, 令随机变量 X 为抽出次品数量, 称其满足超几何分布, 记为 $X \sim H(n, M, N)$, 其分布列为:

$$P\{X = k\} = f(k; n, M, N) = \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}}, 0 \leq k \leq n \leq N, k \leq M$$

当 $N \gg n$ 时, 可以使用二项分布近似.

2.3.4 Poisson 分布

Definition 2.3.4 (Poisson 分布): 设 $\lambda > 0$ 且随机变量 X 可以取一切非负整数, 则称随机变量 X 服从 Poisson 分布, 若:

$$P\{X = k\} = \frac{\lambda^k}{k!} e^{-\lambda}, k \in \mathbb{N}$$

其特征如下:

- 数学期望: $E(X) = \lambda$
- 方差: $D(X) = \lambda$
- 特征函数: $f(t) = e^{\lambda(e^{it}-1)}$

2.3.5 几何分布

Definition 2.3.5 (几何分布): 在成功概率为 p 的 Bernoulli 试验中, 记随机变量 X 为首次试验时试验的次数, 其可能的取值为 $1, 2, \dots$, 则称随机变量 X 服从几何分布, 记为 $X \sim G(p)$, 其分布列为:

$$P\{X = k\} = g(k; p) = p(1-p)^{k-1}, k \in \mathbb{N}^+$$

其特征如下:

- 数学期望: $E = \frac{1}{p}$

同时, 几何分布还具有**无记忆性**, 即若已知前 m 次都没有成功, 设达到首次成功的等待时间为 T , 则 $P(T = k) = p(1-p)^{k-1}, k \in \mathbb{N}^+$ 同 m 无关, 离散分布中只有几何分布有此性质.

2.3.6 Pascal 分布

Definition 2.3.6 (Pascal 分布): 在成功概率为 p 的 Bernoulli 试验中, 记随机变量 X 为成功第 r 次出现时的试验次数, 取值为 $r, r+1, \dots$, 称随机变量 X 服从 Pascal 分布, 其分布列为:

$$P\{X = k\} = \binom{k-1}{r-1} p^r (1-p)^{k-r}, k = r, r+1, \dots$$

上述可推广成负二项分布:

Definition 2.3.7 (负二项分布): 对任意实数 $r > 0$, 称

$$Nb(k; r, p) = \binom{-r}{k} p^r (p-1)^k, k \in \mathbb{N}$$

为负二项分布.

2.4 连续型随机变量及其分布律

Definition 2.4.1 (连续型随机变量、概率密度函数): 设 X 是随机变量, 如果存在非负函数 $f(x)$ 使得对任何满足 $-\infty \leq a < b \leq \infty$ 的 a, b 有:

$$P(a < X \leq b) = \int_a^b f(x) dx$$

就称 X 是连续型随机变量, 称 $f(x)$ 是 X 的概率密度函数, 简称为概率密度.

显然, 概率密度函数满足如下性质:

Theorem 2.4.1: 设 $f(x)$ 是 X 的概率密度, 则 $f(x)$ 有如下的基本性质:

- $\int_{-\infty}^{\infty} f(x) dx = 1$
- $P(X = a) = 0$. 于是可推出 $P(a < X \leq b) = P(a \leq X \leq b)$
- 对数集 A (严格意义下要求可测性) 有: $P(X \in A) = \int_A f(x) dx$

2.5 常见连续型随机变量

2.5.1 均匀分布

Definition 2.5.1 (均匀分布): 设 a, b 为有限数, 则密度函数为:

$$p(x) = \begin{cases} \frac{1}{b-a} & \text{if } a \leq x \leq b \\ 0 & \text{Others} \end{cases}$$

此被称为 $[a, b]$ 上的均匀分布.

- 其分布函数如下:

$$F(x) = \begin{cases} 0 & \text{if } x \leq a \\ \frac{x-a}{b-a} & \text{if } a < x \leq b \\ 1 & \text{if } x > b \end{cases}$$

- 若 θ 服从 $[0, 1]$ 均匀分布, 那么对任意分布函数 $F(x)$, 令 $\xi = F^{-1}(\theta)$, 则不难看出 ξ 是服从分布函数 F 的随机变量.

其特征如下:

- 数学期望: $E(X) = \frac{b+a}{2}$
- 方差: $D(X) = \frac{(b-a)^2}{12}$

2.5.2 正态分布

Definition 2.5.2 (正态分布): 密度函数为

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, x \in \mathbb{R}$$

其中 $\sigma > 0, \mu, \sigma$ 为常数, 上述分布记为 $N(\mu, \sigma^2)$.

- 其分布函数如下:

$$F(x) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^x \frac{e^{-(y-\mu)^2}}{2\sigma^2} dy, x \in \mathbb{R}$$

- 当 $\mu = 0, \sigma = 1$ 时称其为标准正态分布, 其密度函数和分布函数分别记为 ϕ 和 Φ

其具有如下性质:

- 若 $\xi \sim N(\mu, \sigma^2)$, 则 $\eta = \frac{\xi-\mu}{\sigma} \sim N(0, 1)$
- 若 $\xi \sim N(\mu, \sigma^2)$, 则 $F(x) = P\left(\frac{\xi-\mu}{\sigma} < \frac{x-\mu}{\sigma}\right) = \Phi\left(\frac{x-\mu}{\sigma}\right)$, 且 $P(|\xi - \mu| < k\sigma) = 2\Phi(k) - 1$, 且 $P(a \leq \xi \leq b) = \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)$
- 相互独立分布相同的两个随机变量 ξ, η 如果满足密度函数不等于 0 且二阶可导, 且 $\xi + \eta, \xi - \eta$ 相互独立, 那么 $\xi, \eta, \xi + \eta, \xi - \eta$ 都服从正态分布.

其特征如下:

- 数学期望: $E(X) = \mu$
- 方差: $D(X) = \sigma^2$, σ 被称为标准差
- 特征函数: $f(t) = \exp(i\mu t - \frac{1}{2}\sigma^2 t^2)$

2.5.3 指数分布

Definition 2.5.3 (指数分布): 密度函数为

$$p(x) = \begin{cases} \lambda e^{-\lambda x} & \text{if } x \geq 0 \\ 0 & \text{if } x < 0 \end{cases}$$

这里 $\lambda > 0$ 为参数, 称为指数分布, 记为 $\text{Exp}(\lambda)$.

其具有如下性质:

- 无记忆性: 对于任意的 $s, t > 0$, 有 $P(\xi \geq s+t | \xi \geq s) = P(\xi \geq t)$ (连续分布里只有指数分布有此性质)

其特征如下:

- 数学期望: $E = \frac{1}{\lambda}$

2.5.4 Erlang 分布

Definition 2.5.4 (Erlang 分布): 对于任意的 $r \in \mathbb{N}^+, \lambda > 0$, 密度函数:

$$p(x) = \frac{\lambda^r}{(r-1)!} x^{r-1} e^{-\lambda x}, x > 0$$

称为 Erlang 分布.

2.5.5 Γ 分布

Definition 2.5.5 (Γ 分布): 对任意的 $r, \lambda > 0$, 密度函数:

$$f(x) = \begin{cases} \frac{\lambda^r}{\Gamma(r)} x^{r-1} e^{-\lambda x} & \text{if } x > 0 \\ 0 & \text{if } x \leq 0 \end{cases}$$

称为 Γ 分布.

2.5.6 χ^2 分布

Definition 2.5.6 (χ^2 分布): 密度函数为:

$$p(x) = \frac{1}{2^{n/2} \Gamma(n/2)} x^{n/2-1} e^{-(x/2)}, x > 0$$

的分布称为具有自由度 n 的 χ^2 分布, 记作 χ_n^2 .

- 不难得知 χ^2 分布是 Γ 分布的特例.
- 若相对独立的 χ^2 分布 ξ, η 自由度分别为 m, n , 则 $\xi + \eta$ 服从 $m+n$ 的 χ^2 分布.
- 对相对独立且服从 $N(0, 1)$ 的随机变量 ξ_1, \dots, ξ_n , 则 $\eta = \xi_1^2 + \dots + \xi_n^2$ 服从 χ^2 分布.

Chapter 3 多维随机变量

3.1 随机向量及其联合分布

许多情况下，我们关系不止一个随机变量，而是多个随机变量 X_1, \dots, X_n 的相互关系，此时我们可以将这些随机变量作为整体进行研究，故有随机向量定义如下：

Definition 3.1.1 (随机向量): 给定 n 个随机变量 X_1, \dots, X_n ，我们将它们构成的有序组 (X_1, \dots, X_n) 称为 n 维随机向量.

Note: 我们默认将形如 (a_1, \dots, a_n) 的有序组（包括数组和随机向量）均看成列向量.

对于随机向量，上述定义可进行推广如下：

Definition 3.1.2 (离散型随机向量、联合分布列): 若 X_1, \dots, X_n 均为离散型随机变量，则称 $\mathbf{X} = (X_1, \dots, X_n)$ 为离散型随机向量，其联合分布列被定义为函数：

$$p_{X_1, \dots, X_n}(x_1, \dots, x_n) = P\{X_1 = x_1, \dots, X_n = x_n\}$$

3.2 离散型随机向量及其分布律

3.3 常见离散型随机向量

3.3.1 多项分布

Definition 3.3.1 (多项分布): 设试验可能的结果为 A_1, \dots, A_r ， $P(A_i) = p_i$ ，且 $p_1 + \dots + p_r = 1$ ，重复 n 次试验，每次试验独立，记随机变量 X_i 为 A_i 出现次数，则称随机向量 (X_1, \dots, X_r) 服从多项分布，分布列为：

$$P\{X_1 = k_1, \dots, X_r = k_r\} = \frac{n!}{k_1! \dots k_r!} p_1^{k_1} \dots p_r^{k_r}$$

其具有如下性质:

- 协方差: $\text{con}(X_i, X_j) = -np_i p_j$
- 相关系数: $\rho = -\sqrt{\frac{p_i p_j}{(1-p_i)(1-p_j)}}$

3.3.2 多元超几何分布

Definition 3.3.2 (多元超几何分布): 设袋子中有 N_i 个 i 号球, $i = 1, 2, \dots, r$, 且 $N_1 + \dots + N_r = N$, 从中摸出 n 只, 记随机变量 X_i 为 i 号球出现的次数, 则称随机向量 (X_1, \dots, X_r) 服从多元超几何分布, 分布列为:

$$P(X_1 = n_1, \dots, X_r = n_r) = \frac{\binom{N_1}{n_1} \dots \binom{N_r}{n_r}}{\binom{N}{n}}$$

3.4 连续型随机向量及其分布律

3.5 常见连续型随机向量

3.5.1 多元均匀分布

Definition 3.5.1 (多元均匀分布): 若 $G \subset \mathbb{R}^n$ 的正测有限区域, 则密度函数:

$$p(x_1, \dots, x_n) = \begin{cases} \frac{1}{m(G)} & \text{if } (x_1, \dots, x_n) \in G \\ 0 & \text{if } (x_1, \dots, x_n) \notin G \end{cases}$$

称为多元均匀分布.

3.5.2 多元正态分布

Definition 3.5.2 (多元正态分布): 若 $\Sigma = (\sigma_{ij})$ 是 n 阶正定矩阵, 设逆矩阵 $\Sigma^{-1} = (\gamma_{ij})$, 设 $\mu = (\mu_1, \dots, \mu_n)^\top$ 为任意实值列向量, 则有密度函数:

$$\begin{aligned} p(x_1, \dots, x_n) &= \frac{1}{(2\pi)^{n/2}(\det \Sigma)^{1/2}} \exp\left(-\frac{1}{2} \sum_{j,k=1}^n r_{jk}(x_j - \mu_j)(x_k - \mu_k)\right) \\ &= \frac{1}{(2\pi)^{n/2}(\det \Sigma)^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^\top \Sigma^{-1}(\mathbf{x} - \mu)\right) \end{aligned}$$

定义的分佈为 n 元正态分佈, 记为 $N(\mu, \Sigma)$.

Chapter 4 杂七杂八

4.1 概率的连续性

4.2 测度论简介

DRAFT

Chapter 5 Typst 测试章节

5.1 Test Section

§5.1

5.2 Test Test Test 02

DRAFT